

REPORTE INTEGRAL DE ANÁLISIS EXPLORATORIO DE DATOS (EDA)

Diagnóstico Cinemático Multimodal, Evaluación Forense de Calidad de Datos y Guía Metodológica para la Clasificación de Tareas de Rehabilitación Post-ACV (Dataset REHAB)

Proyecto: Reto de Clasificación de Movimientos de Rehabilitación (REHAB-RETO) | **Metodología:** CRISP-DM
Autor: Lead Data Scientist & Senior Kinematics Analyst (+10 años exp) | **Equipo:** Angel Lugo, Jose Pablo, Juan Pablo
Dataset: REHAB - *Rehab_exercise* (Lv et al., *Nature Scientific Data* 2026) | **Scope:** Set de Entrenamiento (N=2,979 ensayos, 70% split estratificado)

DICTAMEN EJECUTIVO DEL SENIOR ANALYST:

Este informe proporciona una auditoría integral, rigurosa y matemática del conjunto de datos de entrenamiento del proyecto **REHAB**. Siguiendo el estándar de 3 pasos para EDA de Miriam Santos (*Towards Data Science*), hemos auditado **31,458,240 registros numéricos cinemáticos** (2,979 ensayos de 15 movimientos post-ACV). Hallazgos clave: (1) **Integridad Numérica Impecable** (0 NaNs, 0 Infs), (2) **Normalización Trial-Wise a Media Cero**, condicionando la energía RMS y varianza como discriminadores primarios, (3) **Razón de Desbalance Moderada** (1.82:1, oscilando entre 148 y 269 muestras por clase) adecuada para modelado directo con estratificación, y (4) **Autopsia Forense de Corrupción** en 014_1.npy en el repositorio fuente (*Science Data Bank*) por decodificación UTF-8, fundamentando la exclusión del Movimiento 14 del benchmark de 12 canales.

1. Contexto Biomédico, Topología de Sensores y Formulación del Reto

El accidente cerebrovascular (ACV) es la principal causa de discapacidad motora en adultos. La neuro-rehabilitación clínica busca restaurar la funcionalidad mediante la repetición sistemática de tareas biomecánicas estandarizadas. El dataset **REHAB** (Lv et al., 2026) captura trayectorias de **120 pacientes post-ACV** durante 2 semanas de terapia bajo el protocolo *Rehab_exercise* (16 ejercicios clínicos).

Topología Multimodal de Sensado (12 Canales Cinemáticos Sincronizados a 880 Timesteps):

- Sensor 1 (Unidad Inercial IMU - Canales 0 a 5):** Dos sensores IMU triaxiales que registran ángulos de Euler (°). En miembro superior se ubican en el brazo proximal (Canales 0-2: Pitch, Yaw, Roll) y antebrazo distal (Canales 3-5: Pitch, Yaw, Roll); en miembro inferior en muslo y pantorrilla.
- Sensor 2 (Guante de Flexión Sensorial + IMU de Muñeca - Canales 6 a 11):** Cinco sensores resistivos de flexión (Canales 6-10: Pulgar F1, Índice F2, Medio F3, Anular F4 y Meñique F5) en unidades arbitrarias continuas proporcionales al ángulo articular, más un sensor inercial en el dorso de la mano (Canal 11: Pitch S5 de muñeca en grados).

Formulación Matemática del Problema: Dado un tensor de entrada $\mathbf{X}_i \in \mathbb{R}^{880 \times 12}$ correspondiente a un ensayo cinemático i , el objetivo del sistema de Machine Learning es clasificar el movimiento ejecutado $y_i \in \mathcal{Y}$, donde $\mathcal{Y} = \{0, 1, \dots, 15\} \setminus \{14\}$ comprende las 15 tareas terapéuticas válidas.

2. Paso 1: Visión General del Dataset y Estadística Descriptiva (Dataset Overview)

Siguiendo la metodología de Miriam Santos, el primer paso responde a: ¿Con qué datos estamos trabajando exactamente?. Para evitar fuga de datos (data leakage), este análisis exploratorio se restringe estrictamente a la partición de **Entrenamiento (X_train, y_train)**, que abarca el 70% del dataset consolidado (2,979 ensayos).

Estructura Numérica y Descriptores Globales:

- **Ensayos de Entrenamiento (N):** 2,979 | **Puntos Temporales (T):** 880 timesteps | **Canales (C):** 12 canales.
- **Volumen Numérico Total:** $2,979 \times 880 \times 12 = 31,458,240$ registros numéricos (240.01 MB en RAM en float64).
- **Integridad de Datos:** 0 valores nulos (NaN = 0), 0 valores infinitos (Inf = 0). Tasa de completitud: 100.0%.

Tabla 1: Resumen Estadístico Descriptivo Exhaustivo por Canal (Set de Entrenamiento, N=2,979)

Canal / Sensor	Tipo Sensor	Media (μ)	Desv. Est. (σ)	Mediana	IQR	Mín / Máx	Asimetría	Curtosis	Outliers %
C00: IMU1_Pitch	IMU Euler	1.3e-16	22.58	0.00	21.33	[-107, 126]	0.18	1.2	7.5%
C01: IMU1_Yaw	IMU Euler	-4.5e-17	29.79	-0.04	17.22	[-787, 302]	-0.93	25.5	14.7%
C02: IMU1_Roll	IMU Euler	-2.1e-17	32.30	0.00	21.92	[-847, 310]	-0.92	21.1	13.9%
C03: IMU2_Pitch	IMU Euler	-1.7e-16	23.06	0.39	25.07	[-101, 87]	-0.30	0.4	3.9%
C04: IMU2_Yaw	IMU Euler	-3.9e-18	23.28	-0.01	11.98	[-606, 870]	1.55	82.1	16.6%
C05: IMU2_Roll	IMU Euler	-2.1e-17	18.14	0.00	9.28	[-459, 865]	-0.10	90.0	14.3%
C06: Glove_Thumb	Flex Sensor	3.3e-16	10.97	0.22	5.30	[-107, 100]	-1.29	15.7	19.1%
C07: Glove_Index	Flex Sensor	2.1e-16	12.61	0.31	7.97	[-107, 98]	-1.14	8.8	14.1%
C08: Glove_Middle	Flex Sensor	-2.4e-17	11.54	0.29	8.30	[-107, 104]	-0.88	7.0	13.2%
C09: Glove_Ring	Flex Sensor	1.8e-16	11.92	0.30	8.63	[-107, 83]	-0.96	6.3	13.1%
C10: Glove_Pinky	Flex Sensor	2.6e-16	11.16	0.27	6.87	[-107, 91]	-0.89	9.0	16.9%
C11: Glove_Pitch	Glove IMU	-1.8e-16	63.42	-0.03	64.17	[-338, 348]	0.08	1.7	5.8%

Balance y Distribución de Clases Terapéuticas en el Set de Entrenamiento:

En clasificación multiclase, el balance determina la propensión al sesgo algorítmico:

- **Clase Mayoritaria:** Movimiento 07 (*Ball gripping*) con **269 muestras** (9.03% del total de entrenamiento).
- **Clase Minoritaria:** Movimiento 01 (*Bobath flexion/extension*) con **148 muestras** (4.97% del total).
- **Razón de Desbalance (Max / Min):** 1.82:1.
- **Entropía de Información de Shannon:** 2.70 nats frente a un máximo teórico de $\$ \ln(15) = 2.708 \$$ nats (**eficiencia informacional: 99.6%**).

Diagnóstico del Senior Analyst: Esta distribución es **razonablemente balanceada** en el contexto biomédico. No se requieren técnicas agresivas de submuestreo o sobremuestreo sintético (SMOTE), pero es imperativo el uso de esquemas de *Stratified K-Fold* y métricas insensibles al desbalance como Macro F1-Score y Balanced Accuracy.

3. Paso 2: Evaluación Profunda de Variables y Visualización (Feature Assessment)




Figura 1: Distribución y balance de muestras por clase en el conjunto de entrenamiento (N=2,979). Se resalta la clase mayoritaria (verde), minoritaria (rojo) y la línea media.

3.1 Análisis Univariado: Morfología Probabilística, Asimetría y Dispersión por Canal

El análisis univariado examina la distribución de cada canal individual a través de sus 2.62 millones de puntos de tiempo:

- **Propiedad de Media Cero (Mean-Centering Artifact):** Todos los canales presentan una media idéntica a cero ($|\mu| < 10^{-15}$). Esto confirma formalmente que las señales fueron normalizadas sustrayendo la media temporal de cada ensayo en la etapa previa de procesamiento (d02_processed_data).
- **Dispersión Cinemática:** Los sensores de flexión de los dedos (Canales 6 a 10) exhiben una desviación estándar compacta ($\sigma \approx 10.9 - 12.6^\circ$), mientras que el ángulo de Pitch de la muñeca (Canal 11) muestra la mayor amplitud angular ($\sigma = 63.42^\circ$), capturando los grandes arcos de flexión-extensión en tareas de manipulación y alcance.
- **Asimetría y Curtosis:** Los canales de flexión digital presentan asimetría negativa (-0.88 a -1.29), indicando que la mano permanece en posición neutra la mayor parte del tiempo con excursiones episódicas de flexión. Los canales 4 (IMU2 Yaw, $\text{curtosis}=82.1$) y 5 (IMU2 Roll, $\text{curtosis}=90.0$) muestran colas extremadamente pesadas, originadas por singularidades angulares de Euler o compensaciones espásticas súbitas en el antebrazo.

3.2 Análisis de Series de Tiempo y Perfiles Cinemáticos Promedio

A diferencia de datos tabulares tradicionales, los datos de REHAB son **series temporales multivariadas continuas**. La **Figura 2** sintetiza las densidades y boxplots de los 12 canales, mientras que la **Figura 3** despliega las trayectorias dinámicas medias (± 1 Desviación Estándar) para cuatro movimientos arquetípicos a lo largo de los 880 timesteps.




Figura 2: Análisis univariado de densidades empíricas, asimetría, curtosis y boxplots para los 12 canales cinemáticos en el conjunto de entrenamiento (31.4M puntos evaluados).

- Hallazgos Clave en Perfiles Temporales:**
- **Mov 00 (Bobath Handshake):** Caracterizado por activación suave y coordinada de sensores proximales (IMU1 Pitch), con mínima oscilación en los dedos del guante.
 - **Mov 05 (Wrist Flexion & Extension):** Muestra oscilaciones periódicas intensas en la muñeca (IMU2) sin reclutamiento de flexión digital aislada.
 - **Mov 07 (Ball Gripping):** Dominado por flexiones profundas y sostenidas en el Pulgar e Índice, con variaciones de alta amplitud.
 - **Mov 15 (Hip Flexion & Extension):** Patrón de miembro inferior con grandes desplazamientos angulares en el muslo y reposo en sensores distales.

3.3 Análisis Multivariado: Interacciones Cruzadas y Matrices de Correlación




Figura 3: Perfiles cinemáticos promedio y bandas de variabilidad inter-sujeto (Media $\pm$ 1 DE) a lo largo de los 880 timesteps para cuatro movimientos arquetípicos.

El análisis multivariado examina la colinealidad, redundancia y acoplamientos biomecánicos entre canales:

- Sinergia y Acoplamiento Digital (Guante Flex):** Se identificó una colinealidad extremadamente alta entre dedos contiguos, destacando **Dedo Medio (C08) vs Dedo Anular (C09)** con $r = 0.88$ ($\rho = 0.86$), y **Anular (C09) vs Meñique (C10)** con $r = 0.81$. Esto refleja la anatomía funcional de los flexores comunes de los dedos de la mano humana.
- Coordinación Proximal-Distal (IMUs):** Correlación positiva moderada entre Pitch del brazo y antebrazo ($r = 0.64$), capturando arcos de flexión del codo.
- Desacoplamiento Modal (IMUs vs Guante):** Las correlaciones cruzadas entre flexión de dedos e inclinación inercial proximal son cercanas a cero ($|r| < 0.15$), confirmando que **ambas modalidades aportan información ortogonal y complementaria**.

3.4 Interacciones Cinemáticas 2D y Dinámica Espectral del Movimiento




Figura 4: Matrices de correlación de Pearson (izquierda) y Spearman (derecha) entre los 12 canales sensoriales en el set de entrenamiento.




Figura 5: Diagramas de dispersión 2D mostrando colinealidad digital (izq), coordinación IMU (centro) y desacoplamiento proximal/distal (der).

Dinámica en Dominio de Frecuencia (FFT / Welch PSD):
El análisis espectral demuestra que el **95% de la energía cinemática voluntaria se concentra por debajo de 3.5 Hz**. Las frecuencias superiores a 5.0 Hz corresponden a temblores involuntarios y ruido de cuantización, lo que permite la aplicación segura de filtros pasabajas Butterworth (corte ~ 6 Hz).

3.5 Análisis Espectral y Separabilidad de Clases en Espacio Latente




Figura 6: Densidad Espectral de Potencia (PSD / Welch) mostrando concentración de energía cinemática en frecuencias bajas (<3.5 Hz).




Figura 8: Proyecciones en espacio latente (PCA 2D y t-SNE) a partir de 60 features agregadas por ensayo, demostrando clusters compactos y separables.

Separabilidad en Espacio Latente: Al proyectar 60 features agregadas por trial mediante t-SNE, las 15 clases forman conglomerados compactos y diferenciables. Se observa solapamiento parcial únicamente dentro de la familia Bobath (Mov 01, 02 y 03) debido a arcos de movimiento compartidos.

4. Paso 3: Evaluación Rigurosa de Calidad de Datos (Data Quality Evaluation)

4.1 Autopsia Forense del Dato Corrupto: Movimiento 14 (knee flexion and extension)

Diagnóstico Forense a Nivel de Bytes:

El archivo oficial 014_1.npy (canales inerciales IMU del Movimiento 14) falla al cargarse mediante np.load(). Nuestra inspección revela que los magic bytes estándar b'\x93NUMPY' fueron reemplazados por b'\n\xef\xbf\xbdNUMPY'. La secuencia 0xEF 0xBF 0xBD corresponde al carácter de sustitución Unicode (U+FFFD), generado cuando un script en el repositorio público de *Science Data Bank* decodificó incorrectamente el archivo binario como texto UTF-8. Esto causó una pérdida destructiva e irrecoverable de los bytes flotantes, inflando el tamaño a 26.97 MB (frente a 15.16 MB esperados).

Veredicto del Senior Analyst: El Movimiento 14 debe ser formalmente excluido del benchmark multimodal de 12 canales.

4.2 Detección de 'Data Smells', Ceros Exactos y Outliers Fisiológicos

- **Sesgo de Media Cero (Mean-Centering):** La posición angular absoluta fue eliminada en el preprocesamiento; los modelos deben clasificar basándose exclusivamente en la **cinemática diferencial relativa** (amplitud, RMS y frecuencias).
- **Ceros Exactos (1.69% de los datos):** 531,770 valores numéricos corresponden exactamente a 0.0, reflejando fases de reposo estático antes y después de cada repetición.
- **Outliers Fisiológicos (3.9% a 19.1%):** Corresponden a espasticidad motora y picos de aceleración genuinos de pacientes post-ACV, por lo que no deben ser podados indiscriminadamente.




Figura 7: Diagnóstico de calidad de datos. Izquierda: Tasas de outliers por IQR y ceros. Derecha: Auditoría de integridad de canales disponibles en los 16 movimientos.

5. Recomendaciones Estratégicas y Roadmap Data-Centric para Modelado

Área del Pipeline	Hallazgo EDA	Recomendación Técnica del Senior Analyst
Feature Engineering	Media trial-wise igual a 0. Información en varianza y RMS.	Para modelos tabulares (LightGBM, Random Forest, SVM): Extraer por canal: RMS, Desviación Estándar, Valor Pico a Pico, Energía Espectral (Welch) y Correlaciones Cruzadas (~60 a 96 features consolidadas).
Deep Learning (1D-CNN / Bi-LSTM)	Señales multivariadas continuas de 880 puntos temporales.	Implementar arquitecturas ResNet-1D o Bi-LSTM sobre el tensor crudo \$(N, 880, 12)\$ normalizado por canal con Z-Score global del set de entrenamiento.
Manejo del Movimiento 14	Archivo 014_1.npy corrupto en la fuente.	Recomendado: Excluir Movimiento 14 del benchmark de 12 canales (15 clases, N=4,257 total). Reportar experimento secundario solo con guante.
Esquema de Validación	Desbalance moderado (1.82:1).	Aplicar Stratified 5-Fold Cross Validation garantizando separación por sujeto para evitar fuga de datos clínicos. Evaluar con Macro F1-Score.
Filtros Digitales	Energía concentrada < 3.5 Hz.	Aplicar filtro pasabajas digital Butterworth 4to orden (fc = 6.0 Hz) para atenuar micro-vibraciones sin alterar la cinemática voluntaria.

6. Conclusiones y Próximos Pasos del Equipo

Síntesis de Hallazgos: El dataset REHAB presenta una excelente viabilidad para clasificación cinemática multiclase. La combinación de IMUs proximales y guante sensorial distal proporciona firmas cinemáticas ortogonales de alta discriminación. La documentación de la media trial-wise en 0 y la degradación de 014_1.npy establece bases metodológicas sólidas para el modelado.

Próximos Pasos: (1) Construir extractor en src/feature_extractor.py, (2) Entrenar baseline tabular (Random Forest / LightGBM) en notebooks/02_baseline_models.ipynb, y (3) Desarrollar arquitectura 1D-CNN sobre el tensor crudo.

Reporte elaborado y certificado por:
Lead Data Scientist & Senior Kinematics Analyst (+10 años de experiencia)
Equipo de Inteligencia Artificial Avanzada para Ciencia de Datos • REHAB-RETO 2026